САМАРСКИЙ УНИВЕРСИТЕТ
SAMARA UNIVERSITY

# Базы данных

## Лекция 12
### MongoDB.
### Расширенные возможности

Агафонов Антон Александрович
к.т.н., доцент кафедры ГИиИБ

Самара

# План лекции

- Расширенные возможности MongoDB
  - Агрегация данных
  - Представления
  - Индексирование
  - Пространственные запросы
  - Транзакции

# Агрегация данных

Операции агрегации данных обрабатывают набор документов и возвращают результаты обработки. Агрегация данных может быть использована для:

- группировки значений из нескольких документов;
- выполнения операций над сгруппированными данными для получения единственного результата;
- анализа изменения данных в течение определенного промежутка времени.

Для агрегации данных используются:

- конвейеры агрегации, которые являются предпочтительным методом агрегирования данных;
- методы агрегации, которые просты, но лишены возможностей конвейера агрегации.

# Методы агрегации данных

| Метод | Описание |
|---|---|
| `db.collection.estimatedDocumentCount()` | Возвращает приблизительное количество документов в коллекции или представлении |
| `db.collection.count()` | Возвращает количество документов в коллекции или представлении |
| `db.collection.distinct()` | Возвращает массив документов, которые имеют различные значения для указанного поля |

# Агрегация данных с использованием метода агрегации

Выборка массива статусов документов без повторений

```
db.inventory.distinct( "status" )
```

```
[ 'A', 'D' ]
```

```
SELECT DISTINCT status FROM inventory;
```

# Конвейер агрегации

Конвейер агрегации состоит из одного или нескольких этапов обработки документов:

- каждый этап выполняет операцию над входными документами. Например, на этапе может происходить фильтрация документов, группировка документов и вычисление некоторых значений;
- документы, полученные как результат работы этапа, передаются на следующий этап;
- конвейер агрегации может возвращать результаты для групп документов, например, вернуть среднее, максимальное и минимальное значения;
- начиная с MongoDB 4.2, конвейер агрегации может использоваться для обновления документов.

# Агрегация данных

```
db.collection.aggregate(
                pipeline, options)

db.collection.aggregate(
        [ { <stage> }, ... ]
)
```

Агрегация данных из коллекции `collection`

- `pipeline` – последовательность операций или этапов агрегации данных;
- `options` – дополнительные параметры.

| Оператор | Описание |
|---|---|
| `$count` | Возвращает количество документов на данном этапе конвейера агрегации. |
| `$group` | Группирует входные документы по указанному выражению-идентификатору и применяет выражения-аккумуляторы, если они указаны, к каждой группе. Выводит по одному документу для каждой отдельной группы. Выходные документы содержат только поле-идентификатор и, если указано, поля-аккумуляторы. |

# Агрегация данных

| Оператор | Описание |
|---|---|
| `$limit` | Передает первые *n* документов без изменений в конвейер, где n – указанное ограничение. Для каждого входного документа выводит либо один документ (для первых n документов), либо ноль документов (после первых n документов). |
| `$lookup` | Выполняет левое внешнее соединение с другой коллекцией в той же базе данных, чтобы фильтровать документы из «объединенной» коллекции для обработки. |
| `$match` | Фильтрует поток документов, позволяя только документам, удовлетворяющим условию, передаваться без изменений на следующий этап конвейера. Использует стандартные запросы MongoDB. |
| `$merge` | Записывает результирующие документы конвейера агрегации в коллекцию. Должен быть последним этапом конвейера. |
| `$project` | Изменяет структуру каждого документа в потоке, например, добавляя новые поля или удаляя существующие поля. Для каждого входного документа выводит один документ. |



| Оператор | Описание |
|---|---|
| `$set` | Добавляет новые поля в документы. Как и `$project`, `$set` изменяет структуру каждого документа; в частности, путем добавления новых полей в выходные документы, которые содержат как существующие поля из входных документов, так и вновь добавленные поля. |
| `$skip` | Пропускает первые *n* документов, где *n* – указанный номер пропуска, и передает остальные документы без изменений в конвейер. |
| `$sort` | Переупорядочивает поток документов по указанному ключу сортировки. Меняется только порядок, документы остаются без изменений. |
| `$unset` | Удаляет/исключает поля из документов. |
| `$unwind` | Преобразует поле массива из входных документов для вывода документа для каждого элемента. Каждый выходной документ заменяет массив значением элемента. Для каждого входного документа выводит *n* документов, где *n* – количество элементов массива, которое может быть равно нулю для пустого массива. |

# Аккумуляторы данных

| Оператор | Описание |
|---|---|
| `$accumulator` | Возвращает результат пользовательской функции-аккумулятора. |
| `$avg` | Возвращает среднее числовых значений. Игнорирует нечисловые значения. |
| `$first` | Возвращает значение из первого документа для каждой группы. Порядок определяется только в том случае, если документы отсортированы. |
| `$last` | Возвращает значение из последнего документа для каждой группы. Порядок определяется только в том случае, если документы отсортированы. |
| `$max` | Возвращает наибольшее значение выражения для каждой группы. |
| `$min` | Возвращает наименьшее значение выражения для каждой группы. |
| `$sum` | Возвращает сумму числовых значений. Игнорирует нечисловые значения. |

# Связь операторов агрегации данных с SQL-операторами

| SQL-операторы и функции | Операторы агрегации в MongoDB |
|---|---|
| WHERE | $match |
| GROUP BY | $group |
| HAVING | $match |
| SELECT | $project |
| ORDER BY | $sort |
| LIMIT | $limit |
| SUM() | $sum |
| COUNT() | $sum<br>$sortByCount |
| JOIN | $lookup |

# Примеры агрегации. Описание данных

Коллекция zipcodes (http://media.mongodb.org/zips.json):

```
{
    _id: "01012",
    city: "CHESTERFIELD",
    pop: 177,
    state: "MA",
    loc: [ -72.833309, 42.38167]
}
```

# Примеры агрегации данных

Подсчет количества записей с популяцией больше 1000 для каждого штата

```
db.zips.aggregate( [ {
    $match: { pop: { $gt: 1000 } }
}, {
    $group: {
        _id: '$state',
        cities_count: { $count: {} }
    }
} ] )
```

```
{ _id: "WV", cities_count: 315}
{ _id: "NM", cities_count: 131}
…
```

```
SELECT state AS _id, COUNT(*) AS cities_count
FROM zips
WHERE pop > 1000
GROUP BY state;
```



# Примеры агрегации данных

Выборка штатов с популяцией больше 10 миллионов

```
db.zips.aggregate( [
    { $group: { _id: "$state", totalPop: { $sum: "$pop" } } },
    { $match: { totalPop: { $gte: 10 * 1000 * 1000 } } }
] )
```

```
{ _id: "OH", totalPop: 10846517 }
{ _id: "FL", totalPop: 12686644 }
{ _id: "IL", totalPop: 11427576 }
…
```

```
SELECT state AS _id, SUM(pop) AS totalPop
FROM zips
GROUP BY state
HAVING totalPop >= 10 * 1000 * 1000;
```

# Примеры агрегации данных

Подсчет среднего населения города по штатам

```
db.zips.aggregate( [
    { $group: { _id: { state: "$state", city: "$city" }, pop: { $sum: "$pop" } } },
    { $group: { _id: "$_id.state", avgCityPop: { $avg: "$pop" } } },
    { $sort: { avgCityPop: -1 } }
] )
```

После первого этапа:

```
{ _id: { state: "CO", city: "EDGEWATER" }, pop: 13154 }
```

После сортировки:

```
{ _id: "DC", avgCityPop: 303450 }
{ _id: "CA", avgCityPop: 27756.42723880597 }
{ _id: "FL", avgCityPop: 27400.958963282937 }
…
```

# Примеры агрегации данных

Поиск городов с наибольшей и наименьшей популяцией для каждого штата

```
db.zips.aggregate( [
    { $group: { _id: { state: "$state", city: "$city" }, pop: { $sum: "$pop" } } },
    { $sort: { pop: 1 } },
    { $group: {
        _id: "$_id.state",
        biggestCity: { $last: "$_id.city" }, biggestPop: { $last: "$pop" },
        smallestCity: { $first: "$_id.city" }, smallestPop: { $first: "$pop" }
      } },
    { $project: {
        _id: 0, state: "$_id",
         biggestCity: { name: "$biggestCity", pop: "$biggestPop" },
         smallestCity: { name: "$smallestCity", pop: "$smallestPop" }
      }
    }
] )

{ state: "AL",
  biggestCity: { name: "BIRMINGHAM", pop: 242606 },
  smallestCity: { name: "ALLEN", pop: 0 }}
…
```

# Примеры агрегации данных

Запись среднего населения города по штатам в новую коллекцию

```
db.zips.aggregate( [
    { $group: { _id: { state: "$state", city: "$city" }, pop: { $sum: "$pop" } } },
    { $group: { _id: "$_id.state", avgCityPop: { $avg: "$pop" } } },
    { $merge: "state_avg_data" }
] )
```

```
db.state_avg_data.find().count()
```

```
51
```

# Представления

Представление (view) – объект базы данных, предназначенный только для чтения, содержимое которого определяется запросом агрегации данных из других коллекций или представлений.

Содержимое представления не сохраняется на диске и вычисляется в момент запроса к представлению.

Преимущества использования представлений:

- исключение некоторой информации из возвращаемых приложению документов, например, персональных данных;
- добавление вычисляемых полей в представление;
- создание представления с использованием сложного контейнера агрегации и скрытие деталей реализации от приложения.

# Создание представления

```
db.createCollection(
   "<viewName>",
   {
      "viewOn" : "<source>",
      "pipeline" : [<pipeline>],
      "collation" : { <collation> }
   }
)
```

Создает новую коллекцию или представление.

```
db.createView(
   "<viewName>",
   "<source>",
   [<pipeline>],
   {
      "collation" : { <collation> }
   }
)
```

Создает новое представление как результат применения указанного конвейера агрегации к исходной коллекции или представлению.

# Пример создания представления

Представление, возвращающее среднее население по штатам

```
db.createView(
    "avgPopulation",
    "zips",
    [
        { $group: { _id: { state: "$state", city: "$city" }, pop: { $sum: "$pop" } } },
        { $group: { _id: "$_id.state", avgCityPop: { $avg: "$pop" } } },
        { $sort: { avgCityPop: -1 } }
    ]
)
```

```
db.avgPopulation.find()
```

```
{ _id: "DC", avgCityPop: 303450 }
{ _id: "CA", avgCityPop: 27756.42723880597 }
{ _id: "FL", avgCityPop: 27400.958963282937 }
…
```

# Пример создания представления с соединением коллекций

Представление, возвращающее результат соединения

```
db.createView("extZips", "zips",
  [
    { $lookup: {
       from: "avgPopulation",
       localField: "state",
       foreignField: "_id",
       as: "avgPopulationDocs"
      }
    },
    { $project: { city: 1, state: 1, pop: 1, avgStatePop: "$avgPopulationDocs.avgCityPop" } },
    { $unwind: "$avgStatePop" }
  ]
)

db.extZips.find()

{ _id: "01035", city: "HADLEY", pop: 4231, state: "MA", avgStatePop: 14855.37037037037 }
…
```

# Модификация представления

| | |
|---|---|
| `db.collection.drop(<options>)` | Удаление коллекции или представления. |
| • Удаление и создание представления заново<br>• Использование команды `collMod` | Изменение представления |

Индекс – объект базы данных, создаваемый с целью повышения производительности поиска данных.

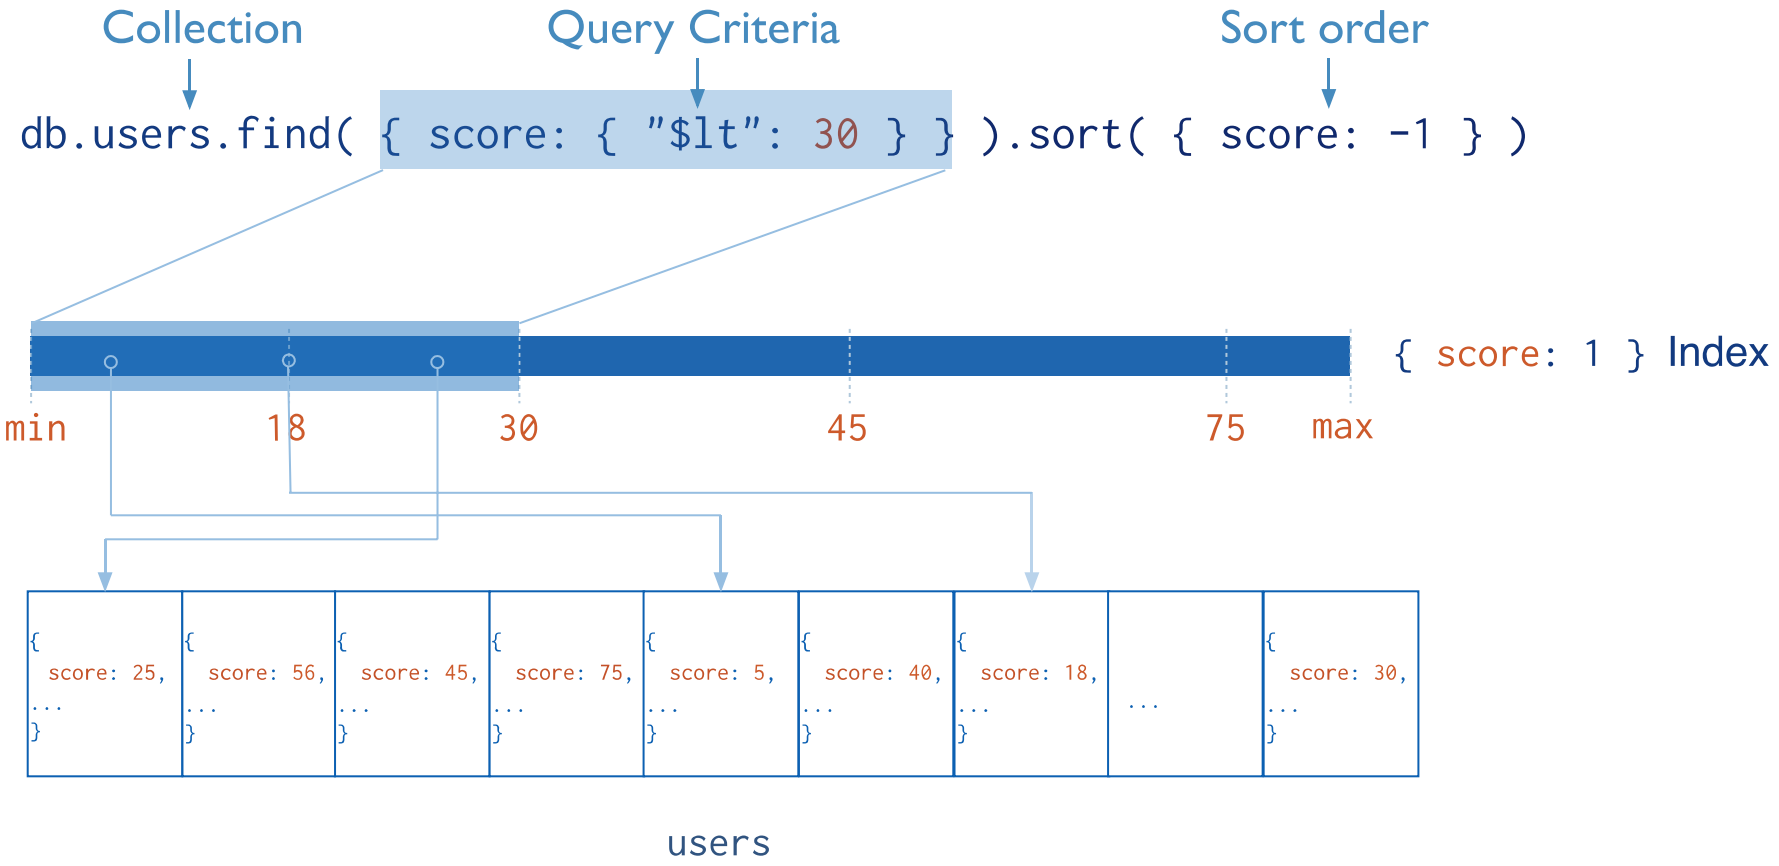

- **Индекс по одному полю**. Поддерживается создание определяемых пользователем индексов по возрастанию/убыванию для одного поля документа. По умолчанию, MongoDB создает уникальный индекс по полю `_id`.

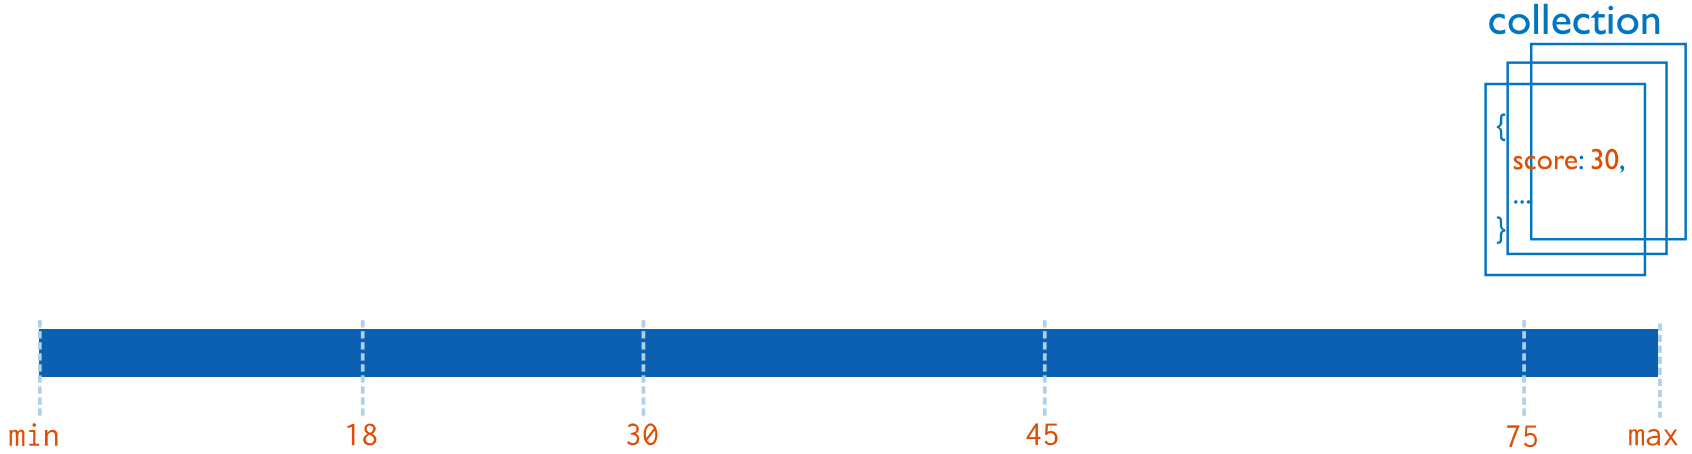

- **Составной индекс**. Поддерживается создание индексов по нескольким полям. Порядок полей, перечисленных в составном индексе, имеет значение.

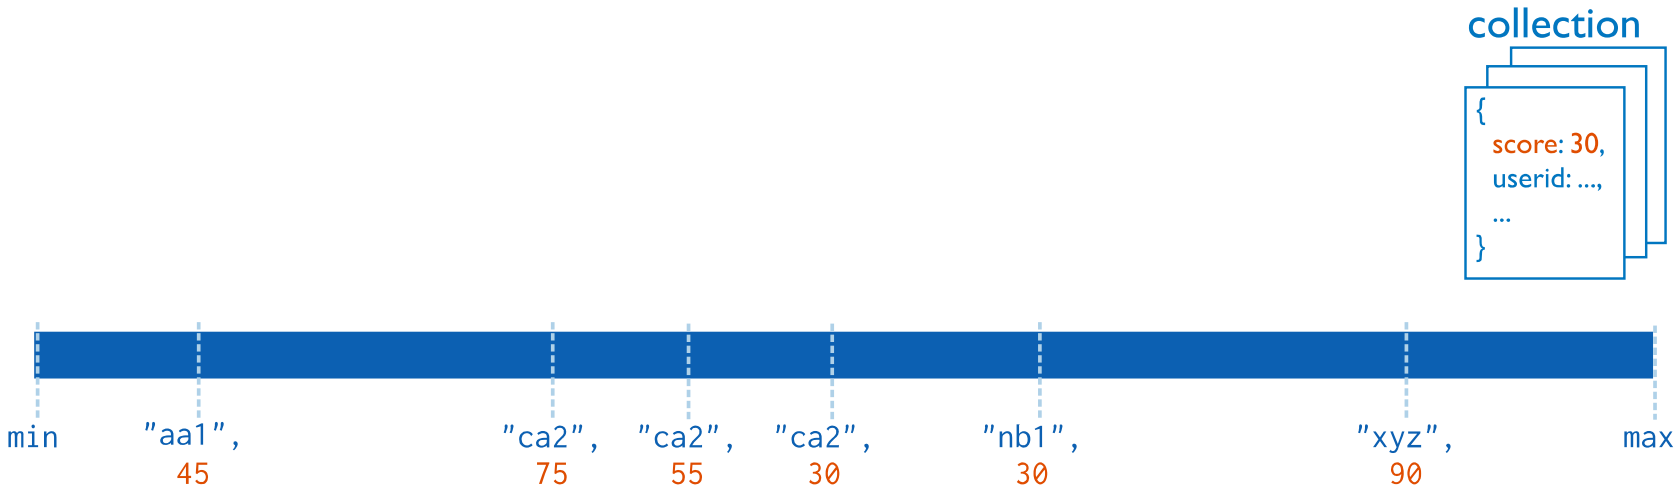

- **Многоключевой (мультиключевой) индекс**. Используется для индексации содержимого, хранящегося в массивах.
  Если индексируется поле, содержащее значение массива, MongoDB создает отдельные записи индекса для каждого элемента массива.

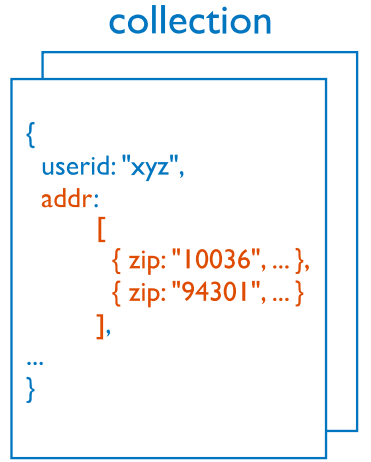



{ "addr.zip": 1 } Index

# Типы индексов

- **Пространственный индекс**. Используется для поддержки эффективных геопространственных запросов. MongoDB предоставляет два специальных индекса: двумерные индексы, которые используют планарную геометрию при возврате результатов, и двумерные индексы, которые используют сферическую геометрию для возврата результатов.
- **Текстовый индекс**. Используется для устаревшего полнотекстового поиска.
- **Хэш-индекс**. Используется для поддержки сегментирования на основе хэша.

# Создание индекса

```
db.collection.createIndex(keys, options, commitQuorum)
```

| | |
|---|---|
| keys | Документ, содержащий пары поля и значения, где поле является ключом индекса, а значение описывает тип индекса для этого поля. Для индекса поля с сортировкой поля по возрастанию указывается значение 1; для индекса по убыванию указывается -1. |
| options | Опциональный параметр. Документ, содержащий набор параметров, управляющих созданием индекса. Поддерживаются параметры name – название индекса, unique – для создания уникального индекса и т.д. |
| commitQuorum | Опциональный параметр. Число реплик, которые должны сообщить об успешном создании индекса. |

**wikipedia**

| **Storage size**: | **Documents**: | **Avg. document size**: | **Indexes**: | **Total index size**: |
|---|---|---|---|---|
| 30.96 GB | 15 M | 4.23 kB | 1 | 532.68 MB |

Выборка количества документов в БД

```
db.wikipedia.find( ).count()
```

*15138138*

# Выполнение запроса

Выборка документов в БД

```
db.wikipedia.find( { _id: "Linkin Park" } )
```

```
{
  _id: 'Linkin Park',
  type: 'page',
  sections: [
    {
      title: '',
      depth: 0,
      sentences: [ { text: 'Linkin Park is an American rock band from Agoura Hills, California.' }, … ]
    }, …
  ],
  categories: [
    'Linkin Park',
    'Alternative rock groups from California', …
  ],
  images: [
    { url: 'https://upload.wikimedia.org/wikipedia/commons/4/42/LinkinParkBerlin2010.jpg', file:
'File:LinkinParkBerlin2010.jpg', … }, …
  ],
  coordinates: [ ], …
  title: 'Linkin Park'
}
```



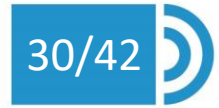

# Анализ запроса, использующего индекс

Выборка документов в БД по идентификатору

```
db.wikipedia.find( { _id: "Linkin Park" } ).explain("executionStats" )
```

```
{ explainVersion: '1',
  queryPlanner:
   { namespace: 'wikipedia.wikipedia',
     indexFilterSet: false,
     parsedQuery: { _id: { '$eq': 'Linkin Park' } },
     winningPlan: { stage: 'IDHACK' },
     rejectedPlans: [] },
  executionStats:
   { executionSuccess: true,
     nReturned: 1,
     executionTimeMillis: 3,
     totalKeysExamined: 1,
     totalDocsExamined: 1,
     executionStages: {stage: 'IDHACK', nReturned: 1, … } },
  command: { find: 'wikipedia', filter: { _id: 'Linkin Park' }, '$db': 'wikipedia' },
}
```

# Анализ запроса без индекса

Выборка документов в БД по названию

```
db.wikipedia.find( { title: "Linkin Park" } ).explain("executionStats" )
```

```
{ explainVersion: '1',
  queryPlanner:
   { namespace: 'wikipedia.wikipedia',
     indexFilterSet: false,
     parsedQuery: { title: { '$eq': 'Linkin Park' } },
     winningPlan:
      { stage: 'COLLSCAN',
        filter: { title: { '$eq': 'Linkin Park' } },
        direction: 'forward' },
     rejectedPlans: [] },
  executionStats:
   { executionSuccess: true,
     nReturned: 1,
     executionTimeMillis: 58712,
     totalKeysExamined: 0,
     totalDocsExamined: 15138138,
     executionStages: { stage: 'COLLSCAN', filter: { title: { '$eq': 'Linkin Park' } }, nReturned: 1, … }
},
  command: { find: 'wikipedia', filter: { title: 'Linkin Park' }, '$db': 'wikipedia' },
}
```



# Анализ запроса, использующего созданный индекса

Выборка документов в БД по названию

```
db.wikipedia.createIndex( { title: 1 } )

db.wikipedia.find( { title: "Linkin Park" } ).explain("executionStats" )
```

```
{ explainVersion: '1',
  queryPlanner:
   { namespace: 'wikipedia.wikipedia',
     indexFilterSet: false,
     parsedQuery: { title: { '$eq': 'Linkin Park' } },
     winningPlan:
      { stage: 'FETCH',
        inputStage:
         { stage: 'IXSCAN', keyPattern: { title: 1 }, indexName: 'title_1', isMultiKey: false, … },
     rejectedPlans: [] },
  executionStats:
   { executionSuccess: true,
     nReturned: 1,
     executionTimeMillis: 13,
     totalKeysExamined: 1,
     totalDocsExamined: 1,
     executionStages: { stage: 'FETCH', nReturned: 1, … } },
  command: { find: 'wikipedia', filter: { title: 'Linkin Park' }, '$db': 'wikipedia' },
}
```



# Выполнение запроса с фильтрацией по значениям в массиве

Выборка документов по категории

```
db.wikipedia.find( { categories: { $all: ["Grammy Award winners"] } }, { _id :1 } )
```

```
…
{ _id: 'Elvis Aaron Presley' }
{ _id: 'Enya' }
{ _id: 'Eric Patrick Clapton' }
{ _id: 'Ennio Morricone' }
{ _id: 'Elvis Costello' }
…
```

# Анализ запроса без индекса

Выборка документов по категории

```
db.wikipedia.find( { categories: { $all: ["Grammy Award winners"] } }, { _id :1 } )

{ …
  executionStats:
   { executionSuccess: true,
     nReturned: 2653,
     executionTimeMillis: 65667,
     totalKeysExamined: 0,
     totalDocsExamined: 15138138,
     executionStages: {
        stage: 'PROJECTION_SIMPLE',
        inputStage:
             { stage: 'COLLSCAN',
               filter: { categories: { '$eq': 'Grammy Award winners' } }, …
             }, …
      }
    }
}
```

# Анализ запроса, использующего индекс

```
db.wikipedia.createIndex( { categories: 1 } )
```

Выборка документов по категории

```
db.wikipedia.find( { categories: { $all: ["Grammy Award winners"] } }, { _id :1 } )
```

```
{ …
  executionStats:
   { executionSuccess: true,
     nReturned: 2653,
     executionTimeMillis: 638,
     totalKeysExamined: 2653,
     totalDocsExamined: 2653,
     executionStages: {
        stage: 'PROJECTION_SIMPLE',
        inputStage:
             { stage: 'IXSCAN',
               filter: { categories: { '$eq': 'Grammy Award winners' } }, …
             }, …
      }
    }
}
```

# Операции над пространственными объектами

| Оператор | Описание |
|---|---|
| `$geoIntersects` | Возвращает геометрию, которая пересекается с указанной геометрией, заданной в формате GeoJSON |
| `$geoWithin` | Возвращает геометрию, которая находится в границах указанной геометрии |
| `$near` | Возвращает геопространственные объекты вблизи указанной точки |
| `$nearSphere` | Возвращает геопространственные объекты вблизи указанной точки на сфере |

# Операции над пространственными объектами

```
db.wikipedia_geo.createIndex( { spatial: "2dsphere" } )
```

Поиск документов вблизи указанного положения

```
db.wikipedia_geo.find( {
    spatial: {
        $near: {
            $geometry: { type: "Point",  coordinates: [ 50.14083, 53.20278 ] },
            $minDistance: 1000,
            $maxDistance: 5000
        }
    }, { _id :1 }
} )
```

```
{ _id: 'Soyuz carrier rocket monument' }
{ _id: 'Samara National Research University' }
{ _id: 'Kuybyshev Square' }
{ _id: 'Stalin\'s bunker' }
{ _id: 'Monument to Vasily Chapaev' }
…
```



# Транзакции

MongoDB – распределенная СУБД с ACID-совместимыми транзакциями между наборами реплик и/или сегментов (шардов).

| **Базовый API** | **API обратного вызова** |
|---|---|
| Требует явного вызова для запуска транзакции и ее фиксации | Запускает транзакцию, выполняет указанные операции и фиксацию (или прерывает работу при возникновении ошибки) |
| Не включает логику обработки ошибок TransientTransactionError и UnknownTransactionCommitResult, вместо этого обеспечивая гибкость, позволяющую включить настраиваемую обработку этих ошибок | Автоматически включает логику обработки ошибок TransientTransactionError и UnknownTransactionCommitResult |
| Требует явного логического сеанса для передачи его в API для конкретной транзакции | Требует явного логического сеанса для передачи его в API для конкретной транзакции |



# Транзакции

| | |
|---|---|
| `Session.startTransaction(<options>)` | Запускает мультидокументную транзакцию, связанную с сеансом. В любой момент времени для сеанса может быть открыта только одна транзакция. |
| `Session.commitTransaction()` | Сохраняет изменения, внесенные операциями в многодокументной транзакции, и завершает транзакцию. |
| `Session.abortTransaction()` | Завершает транзакцию с несколькими документами и откатывает любые изменения данных, сделанные операциями внутри транзакции. То есть транзакция завершается без сохранения каких-либо изменений, сделанных операциями в транзакции. |

# Пример транзакции

```
session = db.getMongo().startSession( );

zips_collection = session.getDatabase("db_lectures").zips;
inv_collection = session.getDatabase("db_lectures").inventory;

session.startTransaction( );

zips_collection.updateOne( { _id: '03101' }, { $set: { pop: 10000} } );
inv_collection.insertOne( { item: 'card', status: 'C', qty: 10 } );

session.commitTransaction();
session.endSession();
```

САМАРСКИЙ УНИВЕРСИТЕТ
SAMARA UNIVERSITY

# БЛАГОДАРЮ ЗА ВНИМАНИЕ

Агафонов А.А.
к.т.н., доцент кафедры ГИиИБ