



# Базы данных

Лекция 13
Знакомство с большими
данными

Агафонов Антон Александрович д.т.н., доцент кафедры ГИиИБ

Самара



## План лекции

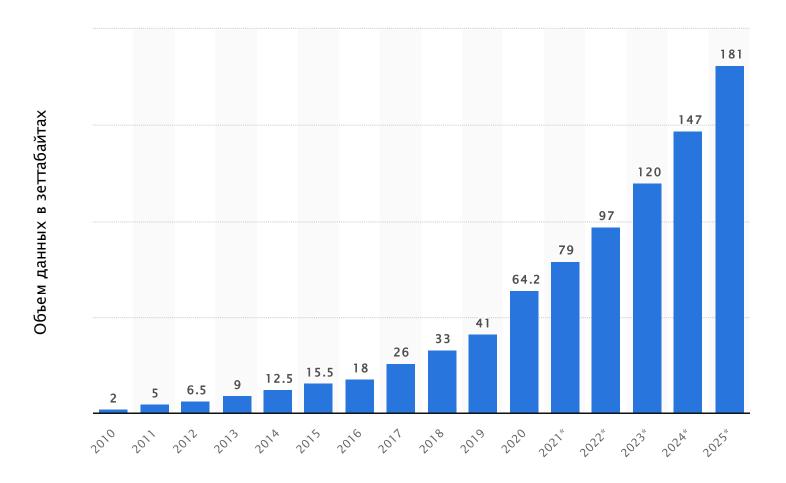
- Понятие больших данных (Big Data)
- Принципы работы с большими данными
- Программное обеспечение для работы с большими данными
- Лямбда-архитектура
- Итоги курса



## Объемы данных в мире

#### Источники данных:

- Интернет вещей
- Социальные сети
- Корпоративные данные
- Медицина и биоинформатика
- Астрономические наблюдения







#### Использование больших данных

- Государственное управление: принятие решений в таких областях, как здравоохранение, занятость населения, экономическое регулирование, борьба с преступностью и обеспечение безопасности, реагирование на чрезвычайные ситуации и т.д.;
- **Промышленность:** повышение прозрачности промышленных процессов и внедрение «предиктивное производство», позволяющее более точно прогнозировать спрос на продукцию и, соответственно, планировать расходование ресурсов;
- **Медицина:** разработка новых лекарств, повышение точности определение диагнозов, подборка эффективного лечения, борьба с пандемий;
- Ретейл: персонализация ассортимента и маркетинга, снижение стоимости доставки;
- Интернет вещей: промышленные и бытовые приборы, подключенные к интернету вещей, собирают огромное количество данных, на основе анализа которых впоследствии регулируется работа этих приборов;
- Спорт: анализ перспективных игроков, разработка эффективных стратегий для каждого противника.





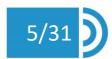
#### Понятие больших данных

Большие данные (Big Data) — это структурированные или неструктурированные данные большого объема и значительного многообразия, эффективно обрабатываемые горизонтально масштабируемыми программными инструментами.

Большие данные (Big Data) — это комплекс технологий, позволяющих обрабатывать как хранящиеся данные, так и поступающий в реальном времени поток разнотипных структурированных и слабоструктурированных данных значительных объемов для получения воспринимаемых человеком результатов.

Технологии обработки больших данных:

- NoSQL
- MapReduce
- Hadoop





## Характеристики больших данных

#### Набор признаков **3V**:

- **Volume** физический объем данных;
- **Velocity** скорость прироста данных и скорость быстрой обработки данных с целью получения результатов;
- Variety вариативность, предполагает возможность одновременной обработки различных типов данных;
- Veracity достоверность как самого набора данных, так и результатов его анализа;
- Variability изменчивость форматов, структуры или источников больших данных;
- Value ценность информации, которую можно получить путем обработки и анализа больших наборов данных.





## Принципы работы с большими данными

#### Технология больших данных призвана обеспечить:

- 1) хранение и управление огромными объемами данных;
- 2) организацию неструктурированных и слабоструктурированных данных (тексты, изображения, видео и т. д.);
- 3) получение из больших данных аналитических выводов, которые будут полезны в практической деятельности человека.

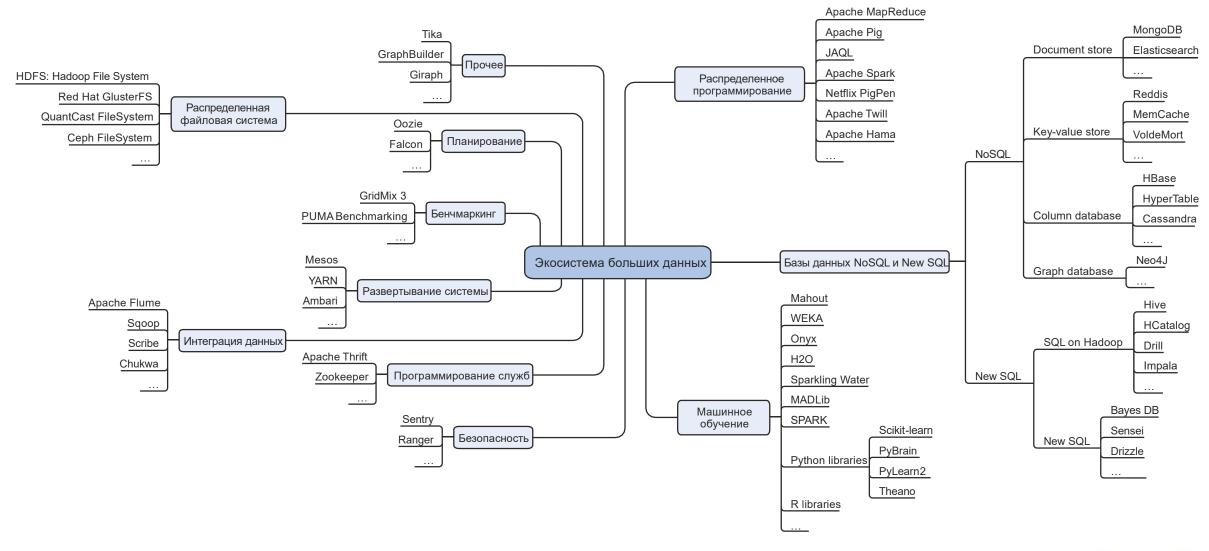
#### Принципы работы с большими данными:

- горизонтальная масштабируемость, обеспечивающая обработку данных, предполагает, что данные распределены по узлам таким образом, что их обработка не приводит к снижению производительности системы;
- отказоустойчивость, должна позволять свести к минимуму влияние на работу с данными возможные отказы оборудования;
- локальность данных, требует, чтобы по возможности данные обрабатывались на том же компьютере, на котором они и хранятся.



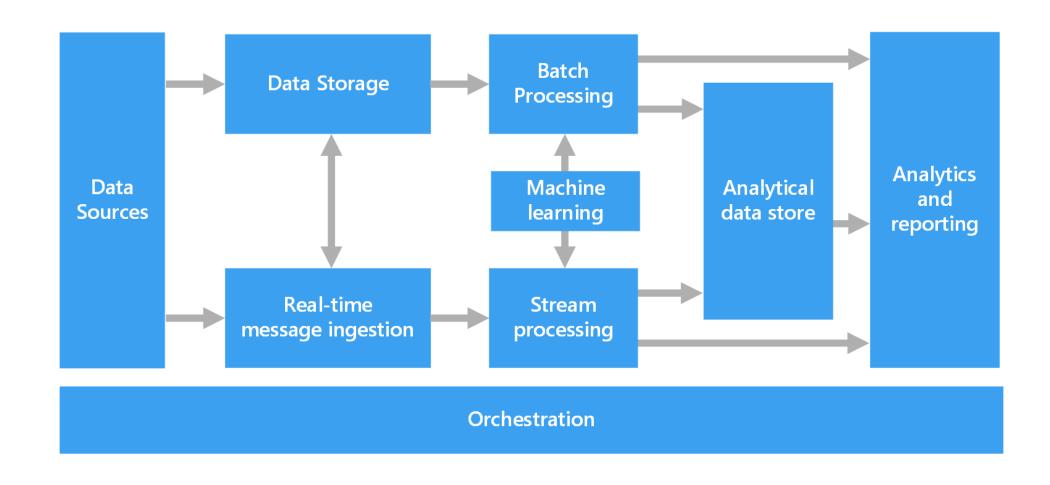


## Программное обеспечение для работы с большими данными





# Компоненты архитектуры больших данных

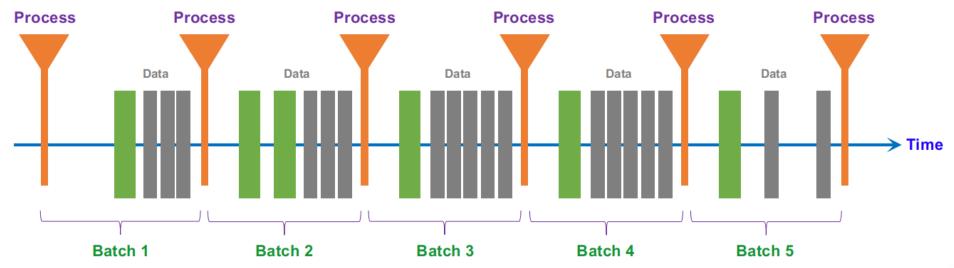




## Пакетная обработка

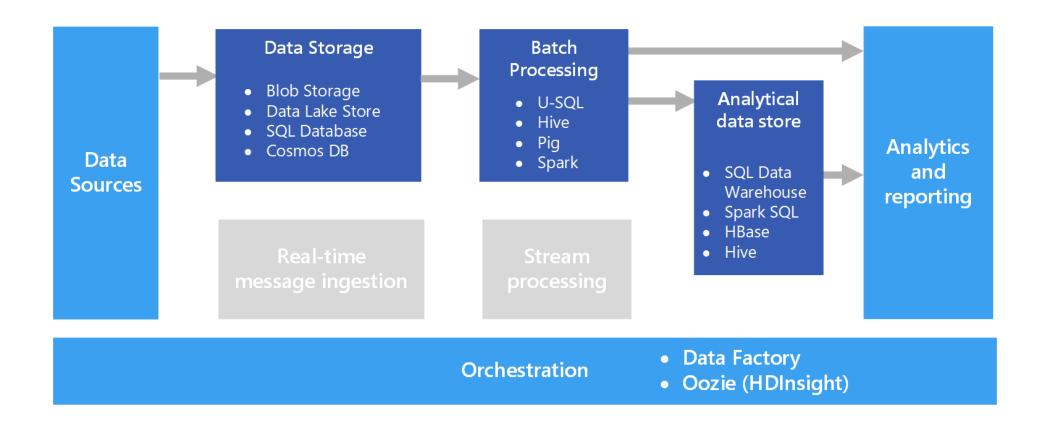
Пакетная обработка (batch processing) — типичный сценарий работы с большими данными. В этом случае исходные данные загружаются в хранилище данных. Затем данные параллельно обрабатываются локально. В рамках обработки может выполняться несколько итеративных шагов до того, как преобразованные результаты будут загружены в хранилище аналитических данных.

- ▲ Высокая эффективность обрабатывается сразу набор данных.
- ▲ Может выполняться для очень больших наборов данных, которые обрабатываются длительное время.
- Результаты обработки доставляются с задержкой.





## Пакетная обработка



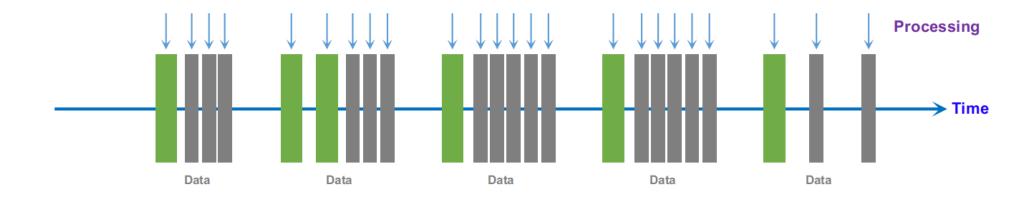




## Потоковая обработка

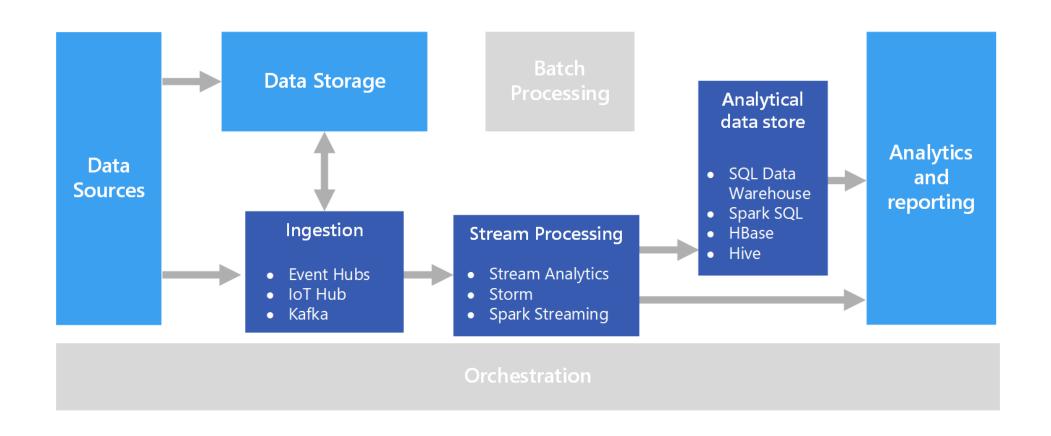
Потоковая обработка (stream processing) выполняется для потоков данных, получаемых в реальном времени и обрабатываемых с минимальной задержкой.

- Непрерывная обработка входящего потока данных по мере поступления событии.
- Низкая задержка до доли секунды.
- ▼ Не могут использоваться сложные сценарии обработки данных.
- Результаты обработки могут быть менее точны или полны, чем при пакетной обработке.





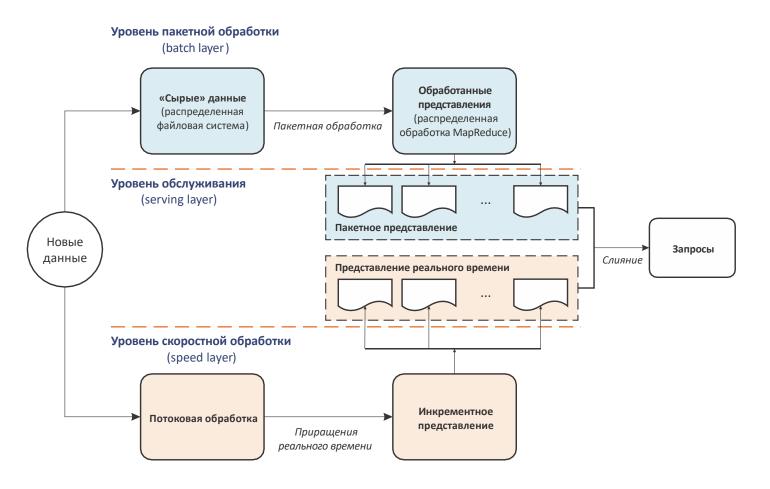
## Потоковая обработка





## Лямбда-архитектура

Лямбда-архитектура (Lambda Architecture) — это подход к процессингу больших данных, который использует преимущества обработки как пакетных, так и потоковых методов обработки.





## Лямбда-архитектура

- Уровень **пакетной обработки** представляет собой хранилище «сырых» данных. Здесь ведется процессинг по расписанию через заранее заданные интервалы времени отправляются запросы к новым данным. Полученные данные добавляются к накопленному ранее архиву, не изменяя его предыдущие копии. Обычно уровень пакетной обработки реализуется на базе *Apache Hadoop*.
- Уровень **скоростной обработки** осуществляет обработку поступающего в реальном времени потока данных. Работа в реальном времени допускает упрощенную обработку, например можно получить недостаточно точные или неполные данные. Однако эти погрешности с небольшим запозданием компенсируются уровнем пакетной обработки. Используемые инструменты: *Apache Spark, Apache Storm, Apache Samza*.
- Данные, полученные от уровней пакетной и скоростной обработки, сохраняются на уровне обслуживания. Слой реагирует на запросы от операторов и возвращает им заранее подготовленные или подготовленные «на лету» представления. На стыке сервисного уровня и уровня скоростной обработки может работать как рассмотренная СУБД MongoDB, так и ряд других систем (Apache Cassandra, Apache HBase).





## Apache Hadoop

**Apache Hadoop** – инфраструктура, упрощающая работу с компьютерными кластерами.

Hadoop пытается достичь следующих целей:

- *Надежность* достигается путем создания нескольких копий данных и повторного применения логики обработки в случае сбоя;
- Отказоустойчивость обнаружение сбоев и применение автоматического восстановления;
- Масштабируемость данные и их обработка распределяются в кластерах (горизонтальное масштабирование);
- *Портируемость* возможность установки на различных устройствах и операционных системах.



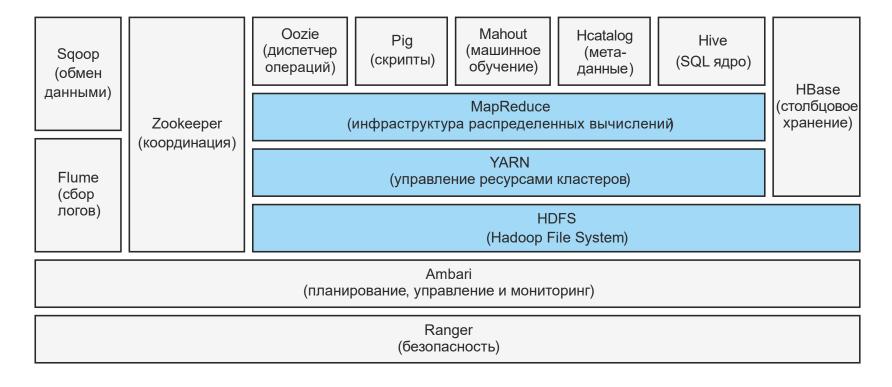




## Основные компоненты Apache Hadoop

В Apache Hadoop центральное место занимают три компонента:

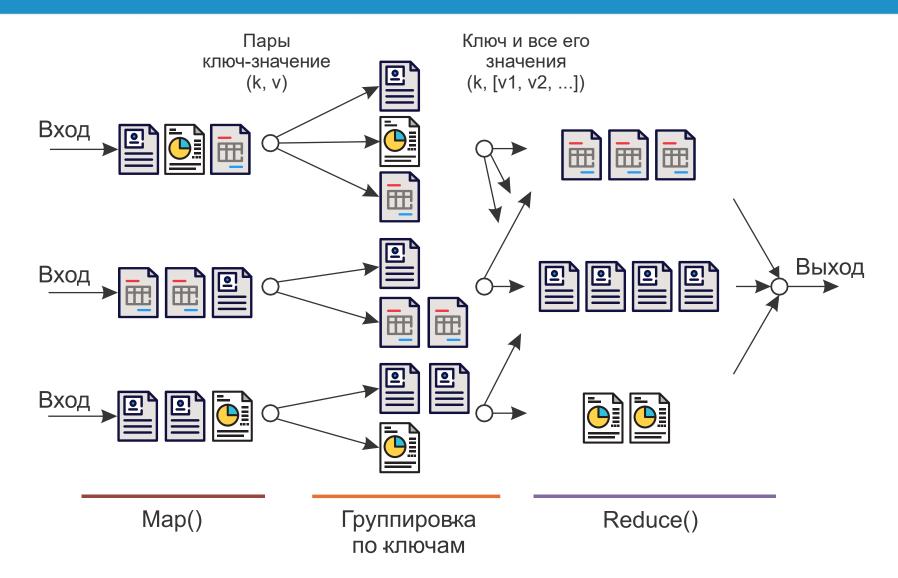
- Распределенная файловая система (Hadoop Distributed File System, HDFS);
- Метод распределенных вычислений MapReduce;
- Система управления ресурсами кластера YARN.







# Подход MapReduce







## Apache Spark

**Apache Spark** — фреймворк с открытым исходным кодом для реализации распределённой обработки неструктурированных и слабоструктурированных данных, входящий в экосистему проектов Hadoop.

- В отличие от классического обработчика из ядра Hadoop, реализующего двухуровневую концепцию MapReduce с хранением промежуточных данных на базе дискового хранилища, Spark работает в парадигме резидентных вычислений обрабатывает данные в оперативной памяти, благодаря чему позволяет получать значительный выигрыш в скорости работы для некоторых классов задач (например, машинного обучения);
- Предоставляет программные интерфейсы для языков Java, Scala, Python, R;
- Поддерживает несколько распределённых систем хранения HDFS, OpenStack Swift, NoSQL-СУБД Cassandra, Amazon S3.



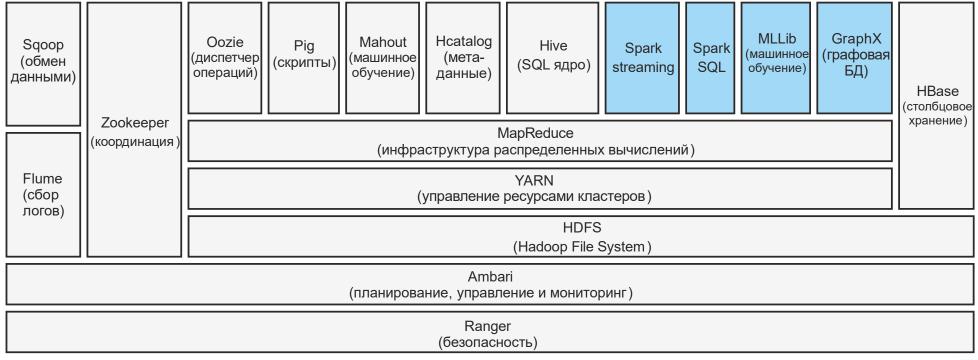




## Основные компоненты Apache Spark

#### Компоненты Apache Spark:

- Spark Streaming инструмент анализа потоковых данных в реальном времени;
- Spark SQL SQL-интерфейс для работы с данными;
- MLLib инструмент машинного обучения в инфраструктуре Spark;
- GraphX графовая база данных для распределенной обработки графов.





## Apache Kafka

**Apache Kafka** — распределенная система обмена сообщениями с высокой пропускной способностью между компонентами программной системы, работающая по принципу «публикация—подписка» (Publish and subscribe). Разрабатывается в рамках фонда Apache.

#### Особенности системы:

- является распределенной, горизонтально-масштабируемой системой, обеспечивающей наращивание пропускной способности как при росте числа и нагрузки со стороны источников, так и количества систем-подписчиков;
- обеспечивается публикация и подписка на потоки записей;
- поддерживается отказоустойчивый способ хранения потоков записей за счет применения техники, сходной с журналами транзакций;
- поток записей обрабатывается по мере появления записей с возможностью временного хранения данных для последующей пакетной обработки.







## Пример системы с лямбда-архитектурой

Система для обработки данных о движении «подключенных» транспортных средств:

- Транспортные средства передают (каждую секунду) информацию о своем положении и мгновенной скорости движения;
- Скорости движения по каждому сегменту сети усредняются (за каждый 5-минутный интервал движения) текущая скорость;
- На основе текущей скорости и архивных данных выполняется прогноз скорости движения на следующий интервал;
- Исходные данные о положения транспортных средств и результат обработки должны быть доступны пользователю посредством веб-приложения.

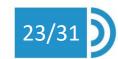




## Пример системы с лямбда-архитектурой

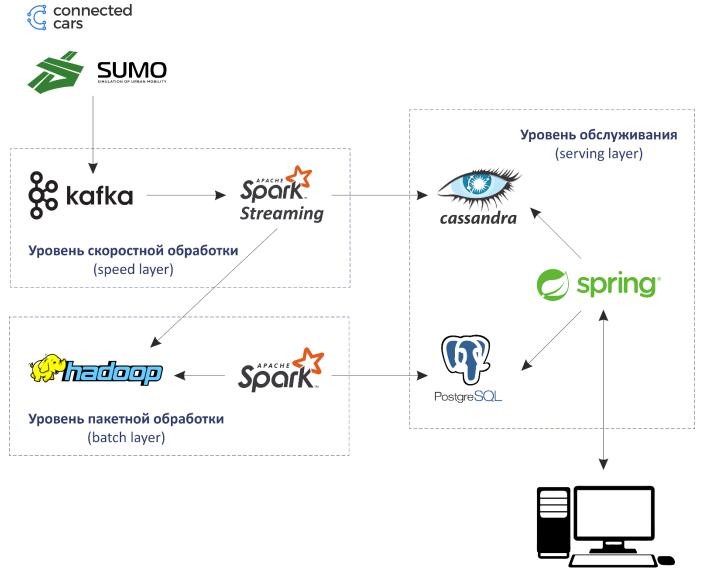
Решаемые системой задачи по уровням обработки лямбда-архитектуры можно распределить следующим образом:

- 1. Уровень скоростной обработки (speed layer) получение новых сообщений о параметрах движения транспортных средств, сохранение данных на диск для последующей пакетной обработки и в БД для выдачи пользователям.
- 2. Уровень пакетной обработки (batch layer) чтение информации с диска и
  - а) усреднение мгновенной скорости за 5-минутный интервал;
  - b) обучение модели прогнозирования скорости движения на основе накопленных данных;
  - с) прогнозирование скорости движения с использованием обученной модели прогнозирования и архивных/текущих данных о скорости движения;
  - d) сохранение результатов анализа в базу данных;
- 3. Уровень обслуживания (service layer) обработка http-запросов пользователей и выдача исходных и обработанных данных.





## Выбранные инструменты

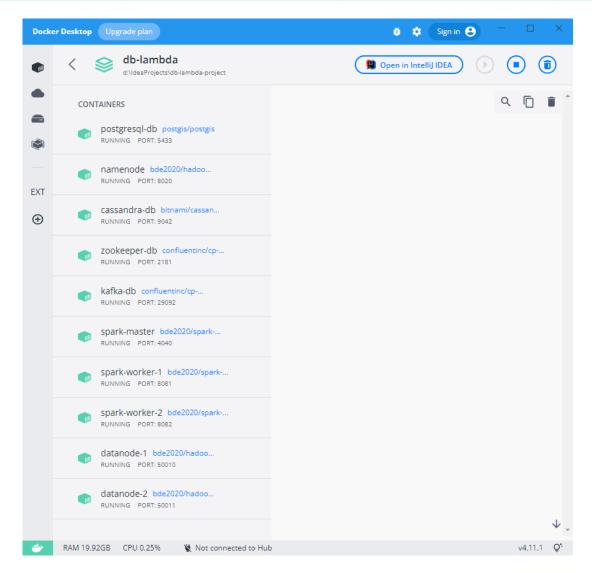






## Развертывание компонентов системы. Docker

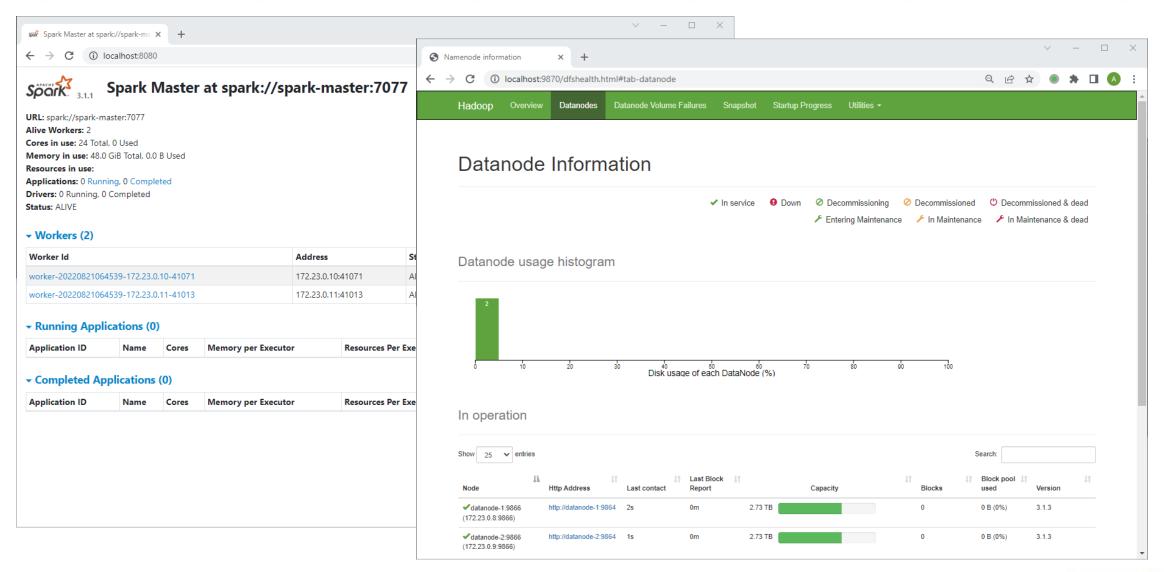
```
services:
 zookeeper:
     image: confluentinc/cp-zookeeper:7.2.1
     container_name: zookeeper-db
 kafka:
     image: confluentinc/cp-kafka:7.2.1
     container_name: kafka-db
 cassandra:
     image: 'bitnami/cassandra:latest'
     container_name: cassandra-db
 postgresql:
     image: postgis/postgis
     container_name: postgresql-db
 spark-master:
     image: bde2020/spark-master:3.1.1-hadoop3.2-java11
     container_name: spark-master
 spark-worker-1:
     image: bde2020/spark-worker:3.1.1-hadoop3.2-java11
     container_name: spark-worker-1
 namenode:
     image: bde2020/hadoop-namenode:2.0.0-hadoop3.1.3-java8
     container_name: namenode
 datanode-1:
     image: bde2020/hadoop-datanode:2.0.0-hadoop3.1.3-java8
     container_name: datanode-1
```





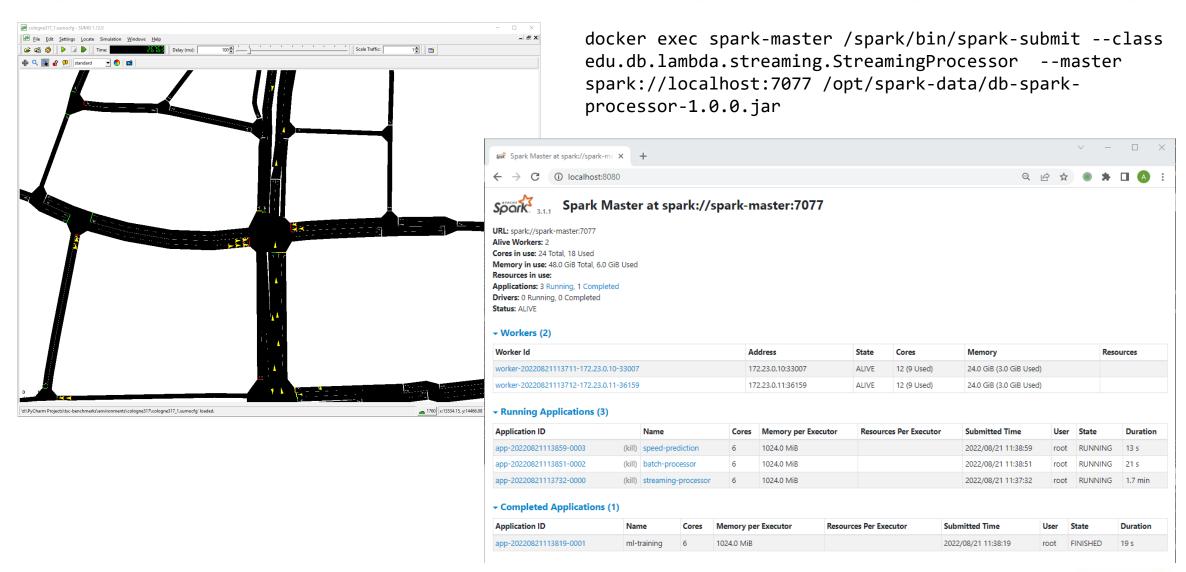


## Проверка компонентов системы. Spark. Hadoop



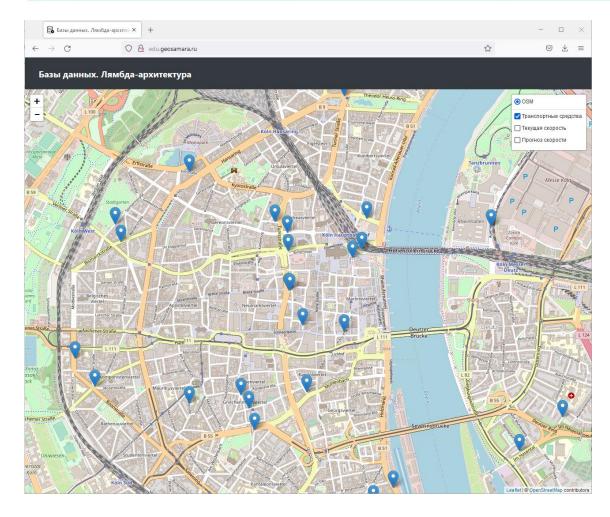


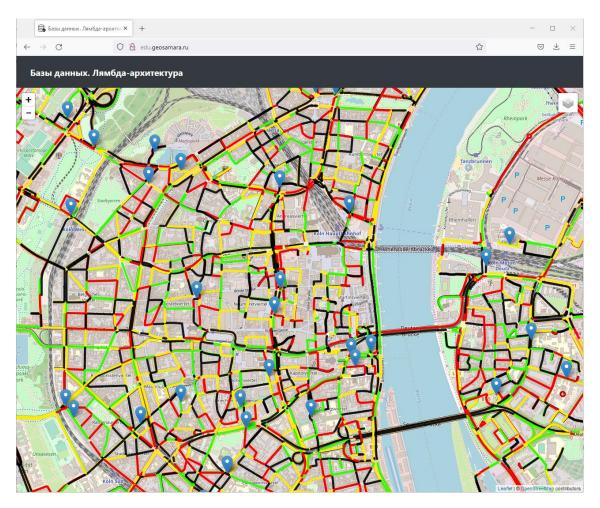
## Обработка данных в Spark





# Отображение результатов анализа







# **(S)**

## Заключение. Рассмотренные темы

- Реляционные базы данных
  - Проектирование баз данных
  - Язык SQL
  - Процедурные расширения языка SQL
  - Транзакции
  - Работа со слабоструктурированными данными
- NoSQL базы данных
  - Типы NoSQL решений
  - Документоориентированная БД MongoDB
- Большие данные





## Заключение. Что осталось за кадром

## Вопросы безопасности в СУБД:

- Резервное копирование данных
- Репликация данных
- Сегментирование (шардинг) баз данных
- Администрирование прав доступа
- Шифрование критических данных







# БЛАГОДАРЮ ЗА ВНИМАНИЕ

Агафонов А.А. д.т.н., доцент кафедры ГИиИБ